

## Горчак Дмитрий, 212. Гауссово распределение: одномерный и двумерный случай. Датчики случайных чисел

Гауссово (нормальное) распределение описывает величину, которая складывается из множества мелких независимых отклонений: результат чаще всего оказывается около среднего значения, а большие отклонения встречаются тем реже, чем они больше. Распределение названо по имени Карла Гаусса, изучавшего ошибки измерений.

Дальше по порядку: одномерный случай и смысл его двух параметров; двумерный случай, где к параметрам добавляется связь между координатами; и устройство датчиков случайных чисел в C++, которыми такие величины получают. Иллюстрации построены по выборкам из учебного проекта cones: рядом с каждым конусом рассыпается облако точек, и от параметров распределения зависит его форма.

### Пункт А. Одномерное распределение

Одномерное нормальное распределение задаётся двумя числами. Первое – математическое ожидание  $\mu$ : значение, около которого группируются результаты, центр распределения. Второе – среднеквадратичное отклонение  $\sigma$ : мера разброса, то есть типичное расстояние от центра. Запись  $N(\mu, \sigma)$  читается «нормальное распределение с центром  $\mu$  и разбросом  $\sigma$ ».

Плотность распределения – функция, показывающая, насколько часто величина попадает в окрестность данной точки. Для нормального закона это колоколообразная кривая: максимум в точке  $\mu$ , симметричные убывающие склоны, площадь под всей кривой равна единице. В показателе экспоненты стоит квадрат отклонения от центра, делённый на удвоенный квадрат  $\sigma$ , – из-за квадрата кривая симметрична, а из-за экспоненты хвосты убывают очень быстро.

$\sigma$  задаёт ширину колокола: чем она больше, тем ниже и шире кривая, потому что площадь под ней всегда единица. Отсюда известные правила, которыми удобно проверять программу:

- 1) в промежуток  $\mu \pm \sigma$  попадает примерно 68.3 процента значений – правило одной сигмы;
- 2) в промежуток  $\mu \pm 2\sigma$  – примерно 95.4 процента; это правило двух сигм, и именно им обычно пользуются, считая выход за такие границы редким событием;
- 3) в промежуток  $\mu \pm 3\sigma$  – примерно 99.7 процента, то есть почти всё.

Параметры распределения заранее не известны, если есть только выборка (набор полученных значений). Их оценивают по самой выборке: среднее значение – сумма всех чисел, делённая на их количество  $n$ , – оценивает  $\mu$ ; корень из среднего квадрата отклонений от среднего оценивает  $\sigma$ . Чем больше  $n$ , тем ближе оценки к настоящим значениям.

Проверить совпадение теории и выборки удобно гистограммой: область значений делится на одинаковые полосы, и для каждой рисуется столбик высотой в долю попавших в неё чисел. Если высоту пересчитать на ширину полосы, столбики ложатся на теоретическую кривую плотности. На рисунке –

выборка из 5000 чисел с  $\mu = 0$  и  $\sigma = 1$ ; программа сосчитала по ней среднее 0.015 и отклонение 1.014, внутрь одной сигмы попало 67.9 процента значений, внутрь двух – 95.6 процента, что согласуется с теоретическими 68.3 и 95.4.




Рисунок 1. Гистограмма выборки из 5000 чисел и теоретическая кривая плотности  $N(0, 1)$

## Пункт Б. Двумерное распределение

На плоскости случайная величина – это пара координат  $(x, y)$ . Центр задаётся двумя числами  $\mu_1$  и  $\mu_2$ , разброс – двумя числами  $\sigma_1$  и  $\sigma_2$  (вдоль каждой оси отдельно). Но этого мало: нужно ещё сказать, связаны ли отклонения по осям между собой. Эту связь задаёт коэффициент корреляции  $\rho$  – число от -1 до 1.

Все четыре величины принято записывать матрицей ковариации: на главной диагонали стоят разбросы по осям, а вне её – одинаковые значения, отвечающие за связь координат. В обозначениях сказки матрица имеет вид  $[[\sigma_1, \rho], [\rho, \sigma_2]]$ : диагональ отвечает за то, насколько облако вытянуто вдоль каждой оси, а внедиагональные элементы – за наклон.

Форму облака задают две вещи по отдельности, и разобрать их проще, меняя по одной. Сначала связи нет ( $\rho = 0$ ), и работают только разбросы:

$\sigma_1 = \sigma_2$  – облако круглое: отклониться на одно и то же расстояние по любой оси одинаково вероятно;

$\sigma_1$  больше  $\sigma_2$  – облако вытянуто вдоль оси абсцисс: по  $x$  точки разбегаются дальше, по  $y$  держатся у центра;

$\sigma_2$  больше  $\sigma_1$  – облако вытянуто вдоль оси ординат, то есть то же самое, повернутое на прямой угол.

Во всех трёх случаях оси облака параллельны осям координат – наклонить его разбросами нельзя, как их ни подбирай. На рисунке три облака по 2500

точек с общим центром: слева  $\sigma_1 = \sigma_2 = 1$ , посередине  $\sigma_1 = 2$  и  $\sigma_2 = 0.6$ , справа наоборот.




Рисунок 2. Связи нет ( $\rho = 0$ ): круглое облако, облако вдоль оси абсцисс и облако вдоль оси ординат

Наклон появляется только от  $\rho$ . Теперь разбросы по осям равны, а меняется одно лишь  $\rho$ :

$\rho = 0$  – координаты не связаны: зная  $x$ , ничего нельзя сказать об  $y$ ; это все три облака рисунка 2;

$\rho > 0$  – отклонения согласованы: там, где  $x$  больше среднего, обычно и  $y$  больше среднего. Облако вытянуто из левого нижнего угла в правый верхний;

$\rho < 0$  – отклонения противоположны: большому  $x$  отвечает малый  $y$ , и облако вытянуто из левого верхнего угла в правый нижний;

чем ближе  $|\rho|$  к единице, тем уже облако: при 0.95 оно почти сжимается в полосу;

$|\rho| = 1$  – связь полная, точки ложатся на одну прямую, и облака как такового уже нет.




Рисунок 3. Разбросы по осям равны, меняется только  $\rho$ : 0.7, -0.7 и 0.95

Сравнение рисунков 2 и 3 и есть главный вывод пункта Б: разбросы растягивают облако вдоль осей координат, связь координат его поворачивает. Круглое облако рисунка 2 и наклонные облака рисунка 3 построены одним и тем же датчиком с одинаковыми разбросами – менялось только значение  $\rho$ .

Линии равной плотности двумерного распределения – эллипсы с центром в точке ( $\mu_1$ ,  $\mu_2$ ), и все рисунки выше – это те же эллипсы, показанные точками. При  $\rho = 0$  оси эллипсов параллельны осям координат, при  $\rho$ , отличном от нуля, эллипсы повернуты. Правило двух сигм переносится сюда так: внутри эллипса, построенного на двух сигмах, оказывается подавляющее большинство точек, и именно поэтому при рассеивании точек вокруг конуса разброс берёт равным половине радиуса основания – тогда почти все точки остаются внутри круга основания, а за его пределы выходят лишь единицы.

Показать двумерное распределение можно по-разному. Простейший способ – облако точек, как на рисунке: сразу видны центр, разброс и наклон. Второй способ – поверхность плотности над плоскостью: получается холм с вершиной над центром, и его удобно сравнивать с конусом из основной задачи, потому что у обоих есть высота в центре и спад к краям, только у конуса спад прямолинейный, а у распределения – по экспоненте. Третий способ – карта линий равного уровня, то есть те самые эллипсы: по ним лучше всего видно направление наклона. Четвёртый – двумерная гистограмма: плоскость режется на клетки, и высота столбика над клеткой равна доле попавших в неё точек; при большом числе точек рельеф такой гистограммы повторяет холм плотности.

Оценка параметров по выборке точек делается так же, как в одномерном случае: центр – среднее арифметическое координат всех точек по каждой оси в отдельности, разбросы – средние квадраты отклонений от найденного центра, а  $\rho$  – среднее произведение отклонений по двум осям, делённое на  $\sigma_1$  и  $\sigma_2$ . Если облако получено вокруг известного центра, найденное среднее должно оказаться рядом с ним; расхождение говорит либо о малом числе точек, либо об ошибке в программе.

## Пункт С. Датчики случайных чисел

Обычная программа выполняется строго по шагам, поэтому настоящей случайности в ней нет. Числа выдаёт генератор псевдослучайных чисел (датчик): он хранит внутреннее состояние и по каждому запросу пересчитывает его по фиксированной формуле, выдавая очередное число. Последовательность выглядит беспорядочной, но полностью определяется начальным состоянием – зерном (seed). Одно и то же зерно даёт одну и ту же последовательность, и это не недостаток, а необходимое свойство: расчёт можно повторить и проверить.

В C++ работа с ними разделена на две независимые части, и это главная идея стандартной библиотеки случайных чисел:

- 1) генератор (engine) выдаёт равномерно распределённые целые числа во всём своём диапазоне и ничего не знает о том, зачем они нужны;
- 2) распределение (distribution) берёт эти числа и превращает их в величину с нужным законом – равномерную в заданных границах, нормальную, показательную и так далее.

Разделение позволяет менять одно, не трогая другое: тот же генератор питает и нормальное распределение, и равномерное. Обычный выбор генератора – вихрь Мерсенна (mersenne twister): у него огромный период, то есть последовательность начинает повторяться через число шагов, которого на практике не достичь, и хорошие статистические свойства. Старая функция rand из языка C такими свойствами не обладает: у неё

короткий период и заметные закономерности в младших разрядах, поэтому для моделирования её не используют.

Зерно берут либо постоянным – когда нужен повторяемый результат, как в учебной программе, где зерном взят номер группы, – либо от источника непредсказуемых значений операционной системы, когда повторяемость не нужна.

Преобразование равномерных чисел в нормальные делается не подбором, а по известным преобразованиям. Классическое – преобразование Бокса – Мюллера: из двух независимых равномерных чисел на промежутке от нуля до единицы получаются сразу два независимых числа со стандартным нормальным распределением  $N(0, 1)$ ; одно равномерное число задаёт расстояние от центра через логарифм, второе – угол поворота. На практике библиотеки используют более быстрые варианты того же приёма, но смысл тот же.

Дальше действуют два простых правила. Чтобы из стандартного числа  $z$  получить величину с нужными параметрами, его умножают на  $\sigma$  и прибавляют  $\mu$ . Чтобы получить двумерную величину со связью координат, берут два независимых стандартных числа  $z_1$  и  $z_2$ : первая координата строится по  $z_1$  обычным образом, а во второй вместо чистого  $z_2$  используется смесь  $z_1$  и  $z_2$ , где вес  $z_1$  равен  $\rho$ , а вес  $z_2$  – корню из единицы минус  $\rho$  в квадрате. Такая смесь подобрана так, чтобы разброс по второй оси остался прежним, а согласованность с первой координатой оказалась в точности равной  $\rho$ . Отсюда и требование  $-1 < \rho < 1$ : при  $|\rho| = 1$  под корнем оказывается ноль, и вторая координата перестаёт быть случайной.

Проверять датчик следует не глазами, а числами: посчитать по выборке среднее и отклонение и сравнить с заданными, проверить правила одной и двух сигм, построить гистограмму и наложить на неё теоретическую кривую. Совпадение по всем трём проверкам – достаточное основание считать, что величины получаются правильные.

## Заключение

Нормальное распределение полностью описывается центром и разбросом, а на плоскости к ним добавляется связь координат. Этих трёх понятий хватает и чтобы понять картинку с облаком точек, и чтобы проверить, верно ли работает датчик: теория даёт точные числа – 68.3 и 95.4 процента, – с которыми сравнивают результат.

*[зерно] --> [генератор: равномерные числа] --> [распределение:  $N(\mu, \sigma)$ ]  
[ $z_1, z_2$ ] --> [смесь с весами  $\rho$  и  $\sqrt{1 - \rho^2}$ ] --> [облако с наклоном]*

## Приложение. Памятка по обозначениям

| Обозначение      | Название                      | Смысл                                      | Как проверить по выборке                |
|------------------|-------------------------------|--------------------------------------------|-----------------------------------------|
| $\mu$            | математическое ожидание       | центр распределения                        | среднее арифметическое значений         |
| $\sigma$         | среднеквадратичное отклонение | типичное отклонение от центра              | корень из среднего квадрата отклонений  |
| $N(\mu, \sigma)$ | нормальное распределение      | закон с центром $\mu$ и разбросом $\sigma$ | гистограмма ложится на кривую плотности |
| $\mu_1, \mu_2$   | центр на плоскости            | координаты центра облака                   | средние по каждой оси отдельно          |

|                 |                        |                                                          |                                  |
|-----------------|------------------------|----------------------------------------------------------|----------------------------------|
| rho             | коэффициент корреляции | связь отклонений по осям, наклон облака точек от -1 до 1 |                                  |
| правило 1 сигмы | 68.3 процента          | доля значений внутри $\mu \pm \sigma$                    | сосчитать попадания в промежуток |
| правило 2 сигм  | 95.4 процента          | доля значений внутри $\mu \pm 2\sigma$                   | сосчитать попадания в промежуток |
| зерно (seed)    | начальное состояние    | задаёт всю последовательность                            | повтор запуска даёт те же числа  |
| период          | длина без повторений   | через сколько чисел начнётся повтор                      | свойство выбранного генератора   |