

Горчак Дмитрий, 212. Гауссово распределение: одномерный и двумерный случай. Датчики случайных чисел

Гауссово (нормальное) распределение описывает величину, которая складывается из множества мелких независимых отклонений: результат чаще всего оказывается около среднего значения, а большие отклонения встречаются тем реже, чем они больше. Распределение названо по имени Карла Гаусса, изучавшего ошибки измерений.

Дальше по порядку: одномерный случай и смысл его двух параметров; двумерный случай, где к параметрам добавляется связь между координатами; и устройство датчиков случайных чисел в C++, которыми такие величины получают. Иллюстрации построены по выборкам из учебного проекта cones: рядом с каждым конусом рассыпается облако точек, и от параметров распределения зависит его форма.

Пункт А. Одномерное распределение

Одномерное нормальное распределение задаётся двумя числами. Первое – математическое ожидание μ : значение, около которого группируются результаты, центр распределения. Второе – среднеквадратичное отклонение σ : мера разброса, то есть типичное расстояние от центра. Запись $N(\mu, \sigma)$ читается «нормальное распределение с центром μ и разбросом σ ».

Плотность распределения – функция, показывающая, насколько часто величина попадает в окрестность данной точки. Для нормального закона это колоколообразная кривая: максимум в точке μ , симметричные убывающие склоны, площадь под всей кривой равна единице. В показателе экспоненты стоит квадрат отклонения от центра, делённый на удвоенный квадрат σ , – из-за квадрата кривая симметрична, а из-за экспоненты хвосты убывают очень быстро.

σ задаёт ширину колокола: чем она больше, тем ниже и шире кривая, потому что площадь под ней всегда единица. Отсюда известные правила, которыми удобно проверять программу:

- 1) в промежуток $\mu \pm \sigma$ попадает примерно 68.3 процента значений – правило одной сигмы;
- 2) в промежуток $\mu \pm 2\sigma$ – примерно 95.4 процента; это правило двух сигм, и именно им обычно пользуются, считая выход за такие границы редким событием;
- 3) в промежуток $\mu \pm 3\sigma$ – примерно 99.7 процента, то есть почти всё.

Параметры распределения заранее не известны, если есть только выборка (набор полученных значений). Их оценивают по самой выборке: среднее значение – сумма всех чисел, делённая на их количество n , – оценивает μ ; корень из среднего квадрата отклонений от среднего оценивает σ . Чем больше n , тем ближе оценки к настоящим значениям.

Проверить совпадение теории и выборки удобно гистограммой: область значений делится на одинаковые полосы, и для каждой рисуется столбик высотой в долю попавших в неё чисел. Если высоту пересчитать на ширину полосы, столбики ложатся на теоретическую кривую плотности. На рисунке –

выборка из 5000 чисел с $\mu = 0$ и $\sigma = 1$; программа сосчитала по ней среднее 0.015 и отклонение 1.014, внутрь одной сигмы попало 67.9 процента значений, внутрь двух – 95.6 процента, что согласуется с теоретическими 68.3 и 95.4.




Рисунок 1. Гистограмма выборки из 5000 чисел и теоретическая кривая плотности $N(0, 1)$

Пункт Б. Двумерное распределение

На плоскости случайная величина – это пара координат (x, y) . Центр задаётся двумя числами μ_1 и μ_2 , разброс – двумя числами σ_1 и σ_2 (вдоль каждой оси отдельно). Но этого мало: нужно ещё сказать, связаны ли отклонения по осям между собой. Эту связь задаёт коэффициент корреляции ρ – число от -1 до 1.

Все четыре величины принято записывать матрицей ковариации: на главной диагонали стоят разбросы по осям, а вне её – одинаковые значения, отвечающие за связь координат. В обозначениях сказки матрица имеет вид $[[\sigma_1, \rho], [\rho, \sigma_2]]$: диагональ отвечает за то, насколько облако вытянуто вдоль каждой оси, а внедиагональные элементы – за наклон.

Форму облака задают две вещи по отдельности, и разобрать их проще, меняя по одной. Сначала связи нет ($\rho = 0$), и работают только разбросы:

$\sigma_1 = \sigma_2$ – облако круглое: отклониться на одно и то же расстояние по любой оси одинаково вероятно;

σ_1 больше σ_2 – облако вытянуто вдоль оси абсцисс: по x точки разбегаются дальше, по y держатся у центра;

σ_2 больше σ_1 – облако вытянуто вдоль оси ординат, то есть то же самое, повернутое на прямой угол.

Во всех трёх случаях оси облака параллельны осям координат – наклонить его разбросами нельзя, как их ни подбирай. На рисунке три облака по 2500

точек с общим центром: слева $\sigma_1 = \sigma_2 = 1$, посередине $\sigma_1 = 2$ и $\sigma_2 = 0.6$, справа наоборот.




Рисунок 2. Связи нет ($\rho = 0$): круглое облако, облако вдоль оси абсцисс и облако вдоль оси ординат

Наклон появляется только от ρ . Теперь разбросы по осям равны, а меняется одно лишь ρ :

$\rho = 0$ – координаты не связаны: зная x , ничего нельзя сказать об y ; это все три облака рисунка 2;

$\rho > 0$ – отклонения согласованы: там, где x больше среднего, обычно и y больше среднего. Облако вытянуто из левого нижнего угла в правый верхний;

$\rho < 0$ – отклонения противоположны: большому x отвечает малый y , и облако вытянуто из левого верхнего угла в правый нижний;

чем ближе $|\rho|$ к единице, тем уже облако: при 0.95 оно почти сжимается в полосу;

$|\rho| = 1$ – связь полная, точки ложатся на одну прямую, и облака как такового уже нет.




Рисунок 3. Разбросы по осям равны, меняется только ρ : 0.7, -0.7 и 0.95

Сравнение рисунков 2 и 3 и есть главный вывод пункта Б: разбросы растягивают облако вдоль осей координат, связь координат его поворачивает. Круглое облако рисунка 2 и наклонные облака рисунка 3 построены одним и тем же датчиком с одинаковыми разбросами – менялось только значение ρ .

Линии равной плотности двумерного распределения – эллипсы с центром в точке (μ_1 , μ_2), и все рисунки выше – это те же эллипсы, показанные точками. При $\rho = 0$ оси эллипсов параллельны осям координат, при ρ , отличном от нуля, эллипсы повернуты.

Точки Гаусса в окружности

Теперь соединим это с окружностью на плоскости. Вокруг центра окружности радиуса r рассыпаются точки с $\rho = 0$ и одинаковым разбросом по осям $\sigma = r / 2$. Тогда край окружности лежит ровно на расстоянии двух сигм от центра.

Здесь легко перепутать две разные доли. Для каждой координаты по отдельности работает правило двух сигм: в полосу $x_0 \pm 2\sigma$ попадает 95.4 процента точек. Но внутри самой окружности их меньше: точке нужно не выйти за 2σ сразу по обеим осям, а по расстоянию от центра. Для круглого облака доля точек внутри радиуса 2σ равна $1 - e^{-2}$, то есть 86.5 процента. Проверка на 300 точках вокруг 15 окружностей дала 86.3 процента внутри окружностей и 97 процентов в полосе по x .

Центр облака по выборке считается как среднее арифметическое: $\mu_i = (1/n) \cdot (x_1 + x_2 + \dots + x_n)$, отдельно по x и по y . Чем больше точек, тем ближе μ_i к настоящему центру: на 20 точках среднее отходит от центра до 0.4 сигмы, на 2000 точках вокруг конуса радиуса 3 среднее вышло (9.01; 8.01) при центре (9; 8).

Если спроецировать точки на ось x и построить гистограмму, самый высокий столбец окажется в центре, а к краям высота падает. Приведём высоту гистограммы к высоте конуса h : самый высокий столбец получает высоту h . Тогда на одном рисунке видно, что гистограмма и профиль конуса устроены одинаково – вершина над центром, наибольшее скопление точек в середине. Отличаются они только формой склонов: у конуса прямая, у гистограммы – кривая Гаусса, которая за краем окружности не обрывается, а быстро затухает.




Рисунок 4. Слева: 2000 точек вокруг конуса, окружность – 2σ , крестик – центр, кружок – выборочное среднее. Справа: гистограмма проекции на ось x , приведённая к высоте конуса, кривая Гаусса и профиль конуса

Показать двумерное распределение можно по-разному. Простейший способ – облако точек, как на рисунке: сразу видны центр, разброс и наклон. Второй

способ – поверхность плотности над плоскостью: получается холм с вершиной над центром, и его удобно сравнивать с конусом из основной задачи, потому что у обоих есть высота в центре и спад к краям, только у конуса спад прямолинейный, а у распределения – по экспоненте. Третий способ – карта линий равного уровня, то есть те самые эллипсы: по ним лучше всего видно направление наклона. Четвёртый – двумерная гистограмма: плоскость режется на клетки, и высота столбика над клеткой равна доле попавших в неё точек; при большом числе точек рельеф такой гистограммы повторяет холм плотности.

Оценка параметров по выборке точек делается так же, как в одномерном случае: центр – среднее арифметическое координат всех точек по каждой оси в отдельности, разбросы – средние квадраты отклонений от найденного центра, а ρ – среднее произведение отклонений по двум осям, делённое на σ_1 и σ_2 . Если облако получено вокруг известного центра, найденное среднее должно оказаться рядом с ним; расхождение говорит либо о малом числе точек, либо об ошибке в программе.

Пункт С. Датчики случайных чисел

Обычная программа выполняется строго по шагам, поэтому настоящей случайности в ней нет. Числа выдаёт генератор псевдослучайных чисел (датчик): он хранит внутреннее состояние и по каждому запросу пересчитывает его по фиксированной формуле, выдавая очередное число. Последовательность выглядит беспорядочной, но полностью определяется начальным состоянием – зерном (seed). Одно и то же зерно даёт одну и ту же последовательность, и это не недостаток, а необходимое свойство: расчёт можно повторить и проверить.

В C++ работа с ними разделена на две независимые части, и это главная идея стандартной библиотеки случайных чисел:

- 1) генератор (engine) выдаёт равномерно распределённые целые числа во всём своём диапазоне и ничего не знает о том, зачем они нужны;
- 2) распределение (distribution) берёт эти числа и превращает их в величину с нужным законом – равномерную в заданных границах, нормальную, показательную и так далее.

Разделение позволяет менять одно, не трогая другое: тот же генератор питает и нормальное распределение, и равномерное. Обычный выбор генератора – вихрь Мерсенна (mersenne twister): у него огромный период, то есть последовательность начинает повторяться через число шагов, которого на практике не достичь, и хорошие статистические свойства. Старая функция rand из языка C такими свойствами не обладает: у неё короткий период и заметные закономерности в младших разрядах, поэтому для моделирования её не используют.

Зерно берут либо постоянным – когда нужен повторяемый результат, как в учебной программе, где зерном взят номер группы, – либо от источника непредсказуемых значений операционной системы, когда повторяемость не нужна.

Превращение равномерных чисел в нормальные делается не подбором, а по известным преобразованиям. Классическое – преобразование Бокса – Мюллера: из двух независимых равномерных чисел на промежутке от нуля до единицы получают сразу два независимых числа со стандартным нормальным

распределением $N(0, 1)$; одно равномерное число задаёт расстояние от центра через логарифм, второе – угол поворота. На практике библиотеки используют более быстрые варианты того же приёма, но смысл тот же.

Дальше действуют два простых правила. Чтобы из стандартного числа z получить величину с нужными параметрами, его умножают на σ и прибавляют μ . Чтобы получить двумерную величину со связью координат, берут два независимых стандартных числа z_1 и z_2 : первая координата строится по z_1 обычным образом, а во второй вместо чистого z_2 используется смесь z_1 и z_2 , где вес z_1 равен ρ , а вес z_2 – корню из единицы минус ρ в квадрате. Такая смесь подобрана так, чтобы разброс по второй оси остался прежним, а согласованность с первой координатой оказалась в точности равной ρ . Отсюда и требование $-1 < \rho < 1$: при $|\rho| = 1$ под корнем оказывается ноль, и вторая координата перестаёт быть случайной.

Проверять датчик следует не глазами, а числами: посчитать по выборке среднее и отклонение и сравнить с заданными, проверить правила одной и двух сигм, построить гистограмму и наложить на неё теоретическую кривую. Совпадение по всем трём проверкам – достаточное основание считать, что величины получаются правильные.

Заключение

Нормальное распределение полностью описывается центром и разбросом, а на плоскости к ним добавляется связь координат. Этих трёх понятий хватает и чтобы понять картинку с облаком точек, и чтобы проверить, верно ли работает датчик: теория даёт точные числа – 68.3 и 95.4 процента, – с которыми сравнивают результат.

*[зерно] --> [генератор: равномерные числа] --> [распределение: $N(\mu, \sigma)$]
 [z1, z2] --> [смесь с весами ρ и $\sqrt{1 - \rho^2}$] --> [облако с наклоном]*

Приложение. Памятка по обозначениям

Обозначение	Название	Смысл	Как проверить по выборке
μ	математическое ожидание	центр распределения	среднее арифметическое значений
σ	среднеквадратичное отклонение	типичное отклонение от центра	корень из среднего квадрата отклонений
$N(\mu, \sigma)$	нормальное распределение	закон с центром μ и разбросом σ	гистограмма ложится на кривую плотности
μ_1, μ_2	центр на плоскости	координаты центра облака	средние по каждой оси отдельно
ρ	коэффициент корреляции	связь отклонений по осям, от -1 до 1	наклон облака точек
правило 1 сигмы	68.3 процента	доля значений внутри $\mu \pm \sigma$	сосчитать попадания в промежутки
правило 2 сигм	95.4 процента	доля значений внутри $\mu \pm 2\sigma$	сосчитать попадания в промежутки
зерно (seed)	начальное состояние	задаёт всю последовательность	повтор запуска даёт те же числа
период	длина без повторений	через сколько чисел начнётся повтор	свойство выбранного генератора